

CSCM603130: Sistem Cerdas Probabilistic Reasoning

Fariz Darari, Aruni Yasmin Azizah

Fakultas Ilmu Komputer
Universitas Indonesia

2019/2020 • Semester Ganjil



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \implies *Cavity*



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \implies *Cavity*
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \Rightarrow Cavity
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:
Toothache \Rightarrow Cavity \vee GumProblem \vee Abscess ...



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \Rightarrow *Cavity*
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:
Toothache \Rightarrow *Cavity* \vee *GumProblem* \vee *Abscess* ...
- Masalah: agar aturan tersebut benar, perlu menyatakan banyak sekali (mungkin tak hingga!) penyebab sakit gigi.



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \Rightarrow *Cavity*
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:
Toothache \Rightarrow *Cavity* \vee *GumProblem* \vee *Abscess* ...
- Masalah: agar aturan tersebut benar, perlu menyatakan banyak sekali (mungkin tak hingga!) penyebab sakit gigi.
- Alternatif: ubah menjadi aturan **causal**—menyimpulkan akibat dari sebab:



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \implies *Cavity*
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:
Toothache \implies *Cavity* \vee *GumProblem* \vee *Abscess* ...
- Masalah: agar aturan tersebut benar, perlu menyatakan banyak sekali (mungkin tak hingga!) penyebab sakit gigi.
- Alternatif: ubah menjadi aturan **causal**—menyimpulkan akibat dari sebab: *Cavity* \implies *Toothache*



Knowledge engineering dalam bidang Kedokteran Gigi - 1

- Anda diminta membuat agent untuk membantu diagnosis dokter gigi.
- Dengan menggunakan **aturan diagnosis**—menyimpulkan sebab dari akibat:
Toothache \implies *Cavity*
- Tidak semua pasien sakit gigi karena berlubang, beberapa disebabkan karena gusi bermasalah, nanah, dll:
Toothache \implies *Cavity* \vee *GumProblem* \vee *Abscess* ...
- Masalah: agar aturan tersebut benar, perlu menyatakan banyak sekali (mungkin tak hingga!) penyebab sakit gigi.
- Alternatif: ubah menjadi aturan **causal**—menyimpulkan akibat dari sebab: *Cavity* \implies *Toothache*
- Masalah (lagi!): tidak semua gigi berlubang menyebabkan sakit! Anteseden perlu diperkuat: gigi berlubang bagaimana yang menyebabkan sakit gigi?—**qualification problem**



Knowledge engineering dalam bidang Kedokteran Gigi - 2

Pendekatan logika secara murni sulit karena:

- **Laziness**: perlu menyatakan secara lengkap anteseden maupun konsekuen dari suatu *rule*.
- **Theoretical ignorance**: perlu memiliki teori yang lengkap dalam kedokteran gigi untuk problem ini.
- **Practical ignorance**: bahkan jika teorinya sudah lengkap pun, ada ketidakpastian tentang kondisi seorang pasien karena tidak semua tes dilakukan (butuh banyak biaya, waktu, dst).



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action $A_t =$ pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t *pasti* berhasil mengantarkan penumpang tiba di bandara tepat waktu?



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action $A_t =$ pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t *pasti* berhasil mengantarkan penumpang tiba di bandara tepat waktu?
- Ada banyak masalah:



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action $A_t =$ pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t *pasti* berhasil mengantarkan penumpang tiba di bandara tepat waktu?
- Ada banyak masalah:
 - Tidak bisa memastikan keadaan jalan, kemacetan, dll. (*partially observable*).



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action $A_t =$ pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t *pasti* berhasil mengantarkan penumpang tiba di bandara tepat waktu?
- Ada banyak masalah:
 - Tidak bisa memastikan keadaan jalan, kemacetan, dll. (*partially observable*).
 - Kebenaran informasi tidak bisa dijamin (*noisy sensor*).



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action A_t = pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t pasti berhasil mengantarkan penumpang tiba di bandara tepat waktu?
- Ada banyak masalah:
 - Tidak bisa memastikan keadaan jalan, kemacetan, dll. (*partially observable*).
 - Kebenaran informasi tidak bisa dijamin (*noisy sensor*).
 - Ketidakpastian dalam melakukan tindakan, mis. ban kempes (*nondeterministic*).



Dunia penuh ketidakpastian (*uncertainty*)

- Sebuah taxi agent T mengantarkan penumpang ke bandara untuk terbang ke luar negeri.
Mis. action A_t = pergi ke bandara t menit sebelum pesawat berangkat.
Apakah T dengan action A_t *pasti* berhasil mengantarkan penumpang tiba di bandara tepat waktu?
- Ada banyak masalah:
 - Tidak bisa memastikan keadaan jalan, kemacetan, dll. (**partially observable**).
 - Kebenaran informasi tidak bisa dijamin (**noisy sensor**).
 - Ketidakpastian dalam melakukan tindakan, mis. ban kempes (**nondeterministic**).
 - **Kalaupun** semua hal di atas bisa dinyatakan, *representation* dan *reasoning* pada logical taxi agent akan **luar biasa repot**.



Keterbatasan pendekatan logika murni

Sebuah pendekatan yang murni secara logika...



Keterbatasan pendekatan logika murni

Sebuah pendekatan yang murni secara logika...

- beresiko menyimpulkan dengan **salah**, mis: " A_{60} berhasil mengantarkan penumpang dengan tepat waktu", atau



Keterbatasan pendekatan logika murni

Sebuah pendekatan yang murni secara logika...

- beresiko menyimpulkan dengan **salah**, mis: "*A₆₀ berhasil mengantarkan penumpang dengan tepat waktu*", atau
- kesimpulan terlalu **lemah**, mis: "*A₆₀ berhasil mengantarkan penumpang dengan tepat waktu asal ... nggak ada kecelakaan di tol, dan nggak hujan, dan ban nggak kempes, ...*"



Keterbatasan pendekatan logika murni

Sebuah pendekatan yang murni secara logika...

- beresiko menyimpulkan dengan **salah**, mis: " A_{60} berhasil mengantarkan penumpang dengan tepat waktu", atau
- kesimpulan terlalu **lemah**, mis: " A_{60} berhasil mengantarkan penumpang dengan tepat waktu asal ... nggak ada kecelakaan di tol, dan nggak hujan, dan ban nggak kempes, ..."
- kesimpulan tidak **rational**, mis: kesimpulannya A_{1440} —berhasil mengantarkan tepat waktu, tetapi terpaksa menunggu semalam di bandara...



Keterbatasan pendekatan logika murni

Sebuah pendekatan yang murni secara logika...

- beresiko menyimpulkan dengan **salah**, mis: " A_{60} berhasil mengantarkan penumpang dengan tepat waktu", atau
- kesimpulan terlalu **lemah**, mis: " A_{60} berhasil mengantarkan penumpang dengan tepat waktu asal ... nggak ada kecelakaan di tol, dan nggak hujan, dan ban nggak kempes, ..."
- kesimpulan tidak **rational**, mis: kesimpulannya A_{1440} —berhasil mengantarkan tepat waktu, tetapi terpaksa menunggu semalam di bandara...

Masalah ini bisa diselesaikan dengan **probabilistic reasoning**

"Berdasarkan info yang ada, A_{60} akan berhasil dengan probabilitas 0.04".



Menangani ketidakpastian

- Kalimat seperti " A_{60} akan berhasil dengan probabilitas 0.04" disebut **probabilistic assertion**.



Menangani ketidakpastian

- Kalimat seperti " A_{60} akan berhasil dengan probabilitas 0.04" disebut **probabilistic assertion**.
- Nilai **probabilitas** pada probabilistic assertion **merangkum** efek ketidakpastian (info tak lengkap, tak bisa dijamin kebenarannya, action nondeterministic, dst.) dan menyatakannya sebagai sebuah bilangan.



Menangani ketidakpastian

- Kalimat seperti " A_{60} akan berhasil dengan probabilitas 0.04" disebut **probabilistic assertion**.
- Nilai **probabilitas** pada probabilistic assertion **merangkum** efek ketidakpastian (info tak lengkap, tak bisa dijamin kebenarannya, action nondeterministic, dst.) dan menyatakannya sebagai sebuah bilangan.
- Logical agent menyatakan suatu pernyataan salah, benar, atau tidak ada jawaban. Sedangkan, probabilistic agent menyatakan suatu pernyataan dengan *degree of belief* (derajat keyakinan) antara 0 (pasti salah) sampai dengan 1 (pasti benar).



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata

- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi, adalah 0.8. (berdasarkan *knowledge state*, ada 8 dari 10 pasien punya gigi berlubang, jika diketahui mengalami sakit gigi).



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata

- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi, adalah 0.8. (berdasarkan *knowledge state*, ada 8 dari 10 pasien punya gigi berlubang, jika diketahui mengalami sakit gigi).
- $P(A_{60} | \text{tidak ada laporan kecelakaan}) = 0.06$



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata

- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi, adalah 0.8. (berdasarkan *knowledge state*, ada 8 dari 10 pasien punya gigi berlubang, jika diketahui mengalami sakit gigi).
- $P(A_{60} | \text{tidak ada laporan kecelakaan}) = 0.06$
- Nilai probabilitas sebuah proposition bisa berubah dengan informasi baru.



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata

- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi, adalah 0.8. (berdasarkan *knowledge state*, ada 8 dari 10 pasien punya gigi berlubang, jika diketahui mengalami sakit gigi).
- $P(A_{60} | \text{tidak ada laporan kecelakaan}) = 0.06$
- Nilai probabilitas sebuah proposition bisa berubah dengan informasi baru.
- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi dan adanya pengalaman masalah kesehatan pada gusi, adalah 0.4.



Menangani ketidakpastian

Memaknai *probabilistic assertion*:

“Kalimat X bernilai *true* dengan probabilitas N , $0 \leq N \leq 1$ ”.

Pernyataan tentang knowledge atau belief state dari agent tentang X , **BUKAN** pernyataan tentang X itu sendiri dalam dunia nyata

- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi, adalah 0.8. (berdasarkan *knowledge state*, ada 8 dari 10 pasien punya gigi berlubang, jika diketahui mengalami sakit gigi).
- $P(A_{60} | \text{tidak ada laporan kecelakaan}) = 0.06$
- Nilai probabilitas sebuah proposition bisa berubah dengan informasi baru.
- Probabilitas pasien memiliki gigi berlubang, jika diketahui (*given*) ia menderita sakit gigi dan adanya pengalaman masalah kesehatan pada gusi, adalah 0.4.
- $P(A_{60} | \text{tidak ada laporan kecelakaan, jam 4 pagi}) = 0.15$



Mengambil keputusan rasional dlm ketidakpastian

Andaikan agent mempercayai nilai-nilai sbb.:

$$P(A_{60} | \dots) = 0.04$$

$$P(A_{120} | \dots) = 0.7$$

$$P(A_{150} | \dots) = 0.9$$

$$P(A_{1440} | \dots) = 0.999$$

Tindakan mana yang dipilih?



Mengambil keputusan rasional dlm ketidakpastian

Andaikan agent mempercayai nilai-nilai sbb.:

$$P(A_{60} | \dots) = 0.04$$

$$P(A_{120} | \dots) = 0.7$$

$$P(A_{150} | \dots) = 0.9$$

$$P(A_{1440} | \dots) = 0.999$$

Tindakan mana yang dipilih?

- Tergantung prioritas, mis. ketinggalan pesawat vs. begadang di lobby bandara, dst.
- **Utility theory** digunakan untuk representation dan reasoning terhadap preferensi (memberi nilai utility pada hasil tindakan suatu action).
- **Decision theory** = utility theory + probability theory



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 **Mengukur Ketidakpastian**
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Logical Assertion vs. Probabilistic Assertion

Possible worlds:

- Pada *logical assertion*, kita bisa memastikan dunia mana yang membuat assertion tersebut bernilai benar.
- Pada *probability assertion*, kita **tidak tahu pasti** yang mana, tetapi satu dunia bisa lebih mungkin dari dunia yang lain.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Sample space & probability model

Himpunan semua *possible worlds* disebut **sample space** (Ω). Masing-masing dunia alternatif disebut **sample point**, atau **atomic event** (ω).

Contoh

Jika kita melempar sebuah dadu, maka Ω berisi 6 sample point: $\omega_1 \dots \omega_6$.

Sebuah **probability model** dibangun dari *sample space* di mana tiap *sample point* ω diberi nilai $P(\omega)$ sehingga:

- Setiap nilai antara 0 s/d 1: $0 \leq P(\omega) \leq 1$
- Jumlah nilai seluruh *sample point* = 1: $\sum_{\omega \in \Omega} P(\omega) = 1$

Contohnya, untuk “dunia” dengan lemparan 1 dadu:

$$P(\omega_1) = P(\omega_2) = P(\omega_3) = P(\omega_4) = P(\omega_5) = P(\omega_6) = \frac{1}{6}$$



Sample space & probability model

Himpunan semua *possible worlds* disebut **sample space** (Ω). Masing-masing dunia alternatif disebut **sample point**, atau **atomic event** (ω).

Contoh

Jika kita melempar sebuah dadu, maka Ω berisi 6 sample point: $\omega_1 \dots \omega_6$.

Sebuah **probability model** dibangun dari *sample space* di mana tiap *sample point* ω diberi nilai $P(\omega)$ sehingga:

- Setiap nilai antara 0 s/d 1: $0 \leq P(\omega) \leq 1$
- Jumlah nilai seluruh *sample point* = 1: $\sum_{\omega \in \Omega} P(\omega) = 1$

Contohnya, untuk “dunia” dengan lemparan 1 dadu:

$$P(\omega_1) = P(\omega_2) = P(\omega_3) = P(\omega_4) = P(\omega_5) = P(\omega_6) = \frac{1}{6}$$

Contohnya, untuk “dunia” dengan lemparan 2 dadu:

$$P(\omega_{1,1}) = P(\omega_{1,2}) = \dots = P(\omega_{6,5}) = P(\omega_{6,6}) = \frac{1}{36}$$



Event

- Sebuah **event** A adalah sembarang subset dari sample space Ω .
- Event A mendeskripsikan sebuah **proposition** ϕ : himpunan sample points (*possible worlds*) yang menyebabkan proposition ϕ bernilai benar.
- Probabilitas event A (proposition ϕ) adalah jumlah probabilitas *sample point* anggotanya.

$$P(A) = \sum_{\omega \in A} P(\omega) \text{ atau } P(\phi) = \sum_{\omega \in \phi} P(\omega)$$

- Contoh: Pada lemparan satu dadu, $P(\text{dadu} \geq 4) = 3 \times \frac{1}{6} = \frac{1}{2}$
- Contoh: Pada lemparan dua dadu, $P(\text{dadu}_1 = 5) = 6 \times \frac{1}{36} = \frac{1}{6}$



Prior vs. posterior probability

Suatu event juga dapat dilihat dari ada atau tidaknya informasi tambahan.

Prior probability:

Nilai probability tanpa informasi spesifik (unconditional).

Mis. $P(\text{cavity})$, $P(\text{toothache})$, dst.



Prior vs. posterior probability

Suatu event juga dapat dilihat dari ada atau tidaknya informasi tambahan.

Prior probability:

Nilai probability tanpa informasi spesifik (unconditional).

Mis. $P(\text{cavity})$, $P(\text{toothache})$, dst.

Seringkali, suatu *event* memiliki beberapa informasi tambahan, yang disebut sebagai **evidence**.



Prior vs. posterior probability

Suatu event juga dapat dilihat dari ada atau tidaknya informasi tambahan.

Prior probability:

Nilai probability tanpa informasi spesifik (unconditional).

Mis. $P(\text{cavity})$, $P(\text{toothache})$, dst.

Seringkali, suatu *event* memiliki beberapa informasi tambahan, yang disebut sebagai **evidence**.

Posterior probability:

Nilai probability jika sesuatu informasi spesifik diketahui (conditional).

Mis.: $P(\text{cavity}|\text{toothache})$

Baca: "*probabilitas gigi pasien berlubang jika diketahui ia sakit gigi*"

Definisi *conditional probability*: $P(a|b) = \frac{P(a \wedge b)}{P(b)}$ untuk $P(b) > 0$

Perumusan alternatif (**product rule**): $P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$



Prior vs. posterior probability

Contoh: Sampel pasien

Toothache + + + + + - + + + + + - + + -

Cavity + + - - + + + + + + + + - - -

GumProblem + - - + + + - - - - - - + - -

■ $P(t|c) =$



Prior vs. posterior probability

Contoh: Sampel pasien

Toothache + + + + + - + + + + + - + + -

Cavity + + - - + + + + + + + + - - -

GumProblem + - - + + + - - - - - - + - -

- $P(t|c) = \frac{P(t \wedge c)}{P(c)} = \frac{8/15}{10/15} = 8/10$

- $P(t \wedge c) =$



Prior vs. posterior probability

Contoh: Sampel pasien

Toothache + + + + + - + + + + + - + + -

Cavity + + - - + + + + + + + + - - -

GumProblem + - - + + + - - - - - - + - - -

$$\blacksquare P(t|c) = \frac{P(t \wedge c)}{P(c)} = \frac{8/15}{10/15} = 8/10$$

$$\blacksquare P(t \wedge c) = P(t|c)P(c) = (8/10)(10/15) = 8/15$$



Prior vs. posterior probability

Contoh: Sampel pasien

Toothache	+	+	+	+	+	-	+	+	+	+	+	-	+	+	-
Cavity	+	+	-	-	+	+	+	+	+	+	+	+	-	-	-
GumProblem	+	-	-	+	+	+	-	-	-	-	-	+	-	-	-

- $P(t|c) = \frac{P(t \wedge c)}{P(c)} = \frac{8/15}{10/15} = 8/10$
- $P(t \wedge c) = P(t|c)P(c) = (8/10)(10/15) = 8/15$
- $P(c|t)?$
- $P(t \wedge c)?$
- $P(t|g)?$
- $P(t|c \wedge g)?$



Random variable

- Secara formal, **random variable** adalah fungsi yang memetakan setiap *sample point* ke dalam suatu domain, mis. boolean, integer, real.

Contoh dgn. random variable *Ganjil* pada dadu:

$$Ganjil(\omega_1) = true,$$

$$Ganjil(\omega_2) = false,$$

dst...



Random variable & probability distribution

- Menghitung probabilitas suatu proposisi:

$$P(X = x_i) = \sum_{\omega: X(\omega)=x_i} P(\omega)$$

Contoh dgn. dadu:

$$P(\text{Ganjil} = \text{false}) = P(\neg \text{ganjil}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

- Sebuah *probability model* P menghasilkan **probability distribution** \mathbf{P} :
probabilitas dari *semua* nilai pada suatu *random variable*

Contoh dgn cuaca:

$$P(\text{Weather} = \text{sunny}) = 0.7$$

$$P(\text{Weather} = \text{rain}) = 0.2$$

$$P(\text{Weather} = \text{cloudy}) = 0.08$$

$$P(\text{Weather} = \text{snow}) = 0.02$$

atau disingkat $\mathbf{P}(\text{Weather}) = \langle 0.7, 0.2, 0.08, 0.02 \rangle$, dengan asumsi urutan sbb:
 $\langle \text{sunny}, \text{rain}, \text{cloudy}, \text{snow} \rangle$



Joint probability distribution

- Dalam AI, seringkali *sample point* didefinisikan oleh nilai sekumpulan *random variable*.
- Jadi, *sample space* berisi semua kemungkinan kombinasi nilai semua variable.
- **Joint probability distribution** dari sekumpulan random variable memberikan nilai probability untuk setiap *sample point* tersebut.

Contoh:

Andaikan kita tertarik mengamati hubungan cuaca dengan sakit gigi, contoh **joint probability distribution**-nya, $P(\text{Toothache}, \text{Weather})$:

	Weather			
	<i>sunny</i>	<i>rain</i>	<i>cloudy</i>	<i>snow</i>
<i>Toothache = true</i>	0.144	0.02	0.016	0.02
<i>Toothache = false</i>	0.576	0.08	0.064	0.08



Contoh yang memilukan

Bayangkan masalah dokter gigi, di mana ada 3 *random variable*:

- **Cavity**: apakah pasien memiliki gigi berlubang atau tidak?
- **Toothache**: apakah pasien merasa sakit gigi atau tidak?
- **Catch**: apakah pisau dokter nyangkut di gigi pasien atau tidak?

Full joint probability distribution sbb.:

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

Full joint probability distribution: joint probability distribution untuk *semua* random variable.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Inference dengan full joint distribution probability

Dengan *full joint probability distribution*, probability sembarang proposition bisa dihitung sbg. jumlah probability sample point di mana proposition tersebut bernilai true.

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576



Inference dengan full joint distribution probability

Dengan *full joint probability distribution*, probability sembarang proposition bisa dihitung sbg. jumlah probability sample point di mana proposition tersebut bernilai true.

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$P(\text{toothache}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$$



Inference dengan full joint distribution probability

Dengan *full joint probability distribution*, probability sembarang proposition bisa dihitung sbg. jumlah probability sample point di mana proposition tersebut bernilai true.

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

$$\begin{aligned}
 P(\text{cavity} \vee \text{toothache}) &= 0.108 + 0.012 + 0.072 + 0.008 + \\
 &\quad 0.016 + 0.064 \\
 &= 0.28
 \end{aligned}$$



Inference dengan full joint distribution probability

Dengan *full joint probability distribution*, probability sembarang proposition bisa dihitung sbg. jumlah probability sample point di mana proposition tersebut bernilai true.

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
\neg <i>cavity</i>	.016	.064	.144	.576

Bisa juga menghitung conditional probability:

$$\begin{aligned}
 P(\neg \text{cavity} | \text{toothache}) &= \frac{P(\neg \text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\
 &= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4
 \end{aligned}$$



Normalisasi pada Inference Conditional Probability

$$P(\neg cavity | toothache) = P(\neg cavity \wedge toothache) / P(toothache)$$

$$P(cavity | toothache) = P(cavity \wedge toothache) / P(toothache)$$

Perhatikan bahwa pembagiannya sama!

Disebut **konstanta normalisasi** $\alpha \rightarrow$ supaya jumlahnya 1.

$$\begin{aligned} \mathbf{P}(Cavity | toothache) &= \alpha \mathbf{P}(Cavity, toothache) \\ &= \alpha [\mathbf{P}(Cavity, toothache, catch) + \mathbf{P}(Cavity, toothache, \neg catch)] \\ &= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] \\ &= \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle \end{aligned}$$

Ide utama:

α dapat diperoleh ketika menghitung **distribusi** utk. *query variable* (mis. *Cavity*) \rightarrow semua kemungkinan nilai *Cavity*.



Inference procedure untuk conditional probability

Contoh sebuah "query"

- $P(\neg cavity | toothache)$
- "Berapakah probabilitas gigi Anto tidak berlubang jika diketahui ia menderita sakit gigi?"

- **Query variable**: variable yang ingin dihitung probabilitasnya (*Cavity*)
- **Evidence variable**: variable yang kita tahu nilainya (*Toothache*)
- **Hidden variable**: variable yang tidak kita tahu nilainya (*Catch*)

Inference dengan (full) joint probability distribution:

Diberikan kumpulan *evidence variable* **E**, di mana **e** adalah kumpulan nilai dari variabel tsb, dan *hidden variable* **Y**. $P(X|e)$ adalah penjumlahan probabilitas *query variable* **X** untuk semua kemungkinan nilai **y**:

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Complexity inference dgn full joint distribution

- Jika ada n random variable Boolean, tabel full joint distribution berisi $O(2^n)$ nilai.
- **Space complexity** eksponensial dalam n . Untuk disimpan saja tidak feasible, apalagi **menghitung semua nilainya dari data empiris!**
- **Time complexity** juga eksponensial dalam n : $O(2^n)$.

Dalam kenyataan, masalah probabilistic reasoning melibatkan **ribuan** *random variable*. Kita butuh metode yang lebih efisien!



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 **Efficient probabilistic reasoning**
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Contoh: Gigi dan Cuaca

Mis. ditambahkan random variable *Weather* = $\langle \text{sunny, rain, cloudy, snow} \rangle$ ke masalah dokter gigi (*Cavity*, *Toothache*, *Catch*)

- Dibutuhkan 32 nilai ($4 \times 2 \times 2 \times 2$) untuk tabel full joint distribution-nya.
- Untuk menghitung probabilitas *proposition* mengenai cuaca dan gigi menggunakan product rule:

$$P(\text{cloudy} \wedge \text{toothache}) = P(\text{cloudy} | \text{toothache}) \times P(\text{toothache})$$


- Tapi cuaca dan gigi tidak berhubungan...sehingga bisa kita nyatakan:

$$P(\text{cloudy} | \text{toothache}) = P(\text{cloudy})$$

- Dari sini, dapat kita hitung probabilitasnya:

$$P(\text{cloudy} \wedge \text{toothache}) = P(\text{cloudy}) \times P(\text{toothache})$$

- Tabel full joint distribution dengan 4 variabel (32 nilai) dapat didekomposisi: tabel dengan 3 variabel (8 nilai) dan tabel dengan 1 variabel (4 nilai).



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Independence

- **Independence** menyatakan bahwa ada random variable yang tidak saling mempengaruhi (**independence/absolute independence**).
- Sebagai contoh, gigi dan cuaca tidak saling mempengaruhi, sehingga *Toothache* dan *Weather* dapat dikatakan saling independent.

Dua proposition a dan b independent jhj

$$P(a|b)=P(a) \text{ atau } P(b|a)=P(b) \text{ atau } P(a \wedge b)=P(a) \times P(b)$$

Dua variable A dan B independent jhj

$$P(A|B)=P(A) \text{ atau } P(B|A)=P(B) \text{ atau } P(A, B)=P(A)P(B)$$

- Independence menyederhanakan kompleksitas inferensi (lebih efisien): mengurangi jumlah informasi yang dibutuhkan dalam menyatakan *full joint probability distribution*.
 - Kasus “Gigi dan Cuaca”: 32 vs. 12 nilai *probability distribution*!
- Dalam kenyataan, *absolute independence* jarang terjadi.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Bayes' Rule

Product Rule:

$$P(a \wedge b) = P(a|b)P(b) \quad \text{dan} \quad P(a \wedge b) = P(b|a)P(a)$$

Dengan memanipulasi *product rule* di atas diperoleh **Bayes' Rule**.

Bayes' Rule

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$



Penerapan Bayes' Rule

Seringkali *evidence* yang didapatkan berupa *akibat* dari suatu *sebab* yang belum diketahui dan kita ingin menentukan sebab tersebut. Dalam Bayes' rule:

$$P(\text{Sebab}|\text{Akibat}) = \frac{P(\text{Akibat}|\text{Sebab})P(\text{Sebab})}{P(\text{Akibat})}$$

$P(\text{Akibat}|\text{Sebab})$ menyatakan hubungan **kausal**, sedangkan $P(\text{Sebab}|\text{Akibat})$ menyatakan hubungan **diagnostik**.

Contoh: Dalam diagnosis medis, info ttg hubungan kausal $P(\text{gejala}|\text{penyakit})$ biasanya diketahui, dan diagnosis dilakukan untuk menentukan $P(\text{penyakit}|\text{gejala})$. Untuk menggunakan Bayes' rule, dokter juga memiliki informasi *prior probability* dari gejala yang diobservasi dan *prior probability* penyakit tersebut.



Penerapan Bayes' Rule

Contoh:

Dokter mengetahui penyakit *meningitis* menyebabkan 70% pasien mengalami leher kaku (*stiff neck*). Selain itu, dokter tahu fakta *unconditional*; probabilitas pasien menderita meningitis adalah 1/50,000, dan probabilitas pasien mengalami leher kaku adalah 1%. (*s* sebagai proposisi pasien mengalami leher kaku, *m* sebagai proposisi pasien menderita meningitis)

$$P(s|m) = 0.7$$

$$P(m) = 1/50000$$

$$P(s) = 0.01$$

$$P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0.7 \times 1/50000}{0.01} = 0.0014$$

Untuk mendapat distribusi $\mathbf{P}(M|s)$, yaitu $\langle P(m, s), P(\neg m, s) \rangle$, perhitungan $P(s)$ dapat digantikan dengan menghitung *conditional probability* untuk setiap nilai dari *query variable* *m* dan $\neg m$ lalu normalisasi hasilnya.

$$\mathbf{P}(M|s) = \alpha \langle P(s|m)P(m), P(s|\neg m)P(\neg m) \rangle$$



Bayes' rule dengan kombinasi evidence

- Seringkali ada banyak gejala (akibat) dari suatu penyakit (sebab). Mis. dokter ingin menghitung: $P(\text{Cavity}|\text{toothache} \wedge \text{catch})$
- Dengan tabel full joint probability distribution:

$$P(\text{Cavity}|\text{toothache} \wedge \text{catch}) = \alpha \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle$$
 Masalah: eksponensial terhadap banyaknya variabel evidence.
- Dengan Bayes' rule:

$$P(\text{Cavity}|\text{toothache} \wedge \text{catch}) = \alpha P(\text{toothache} \wedge \text{catch}|\text{Cavity})P(\text{Cavity})$$
 Masalah: dibutuhkan *conditional probability* untuk kombinasi nilai variabel-variabel evidence (eksponensial terhadap banyaknya variabel).
- **Solusi:** conditional independence



Conditional Independence

- Mis. dalam kedokteran gigi, ratusan *variable* biasanya berhubungan
→ absolute independence jarang terjadi.
- Tapi hubungan itu bisa **langsung** atau **tidak langsung**!

Conditional independence

cavity mempengaruhi probabilitas *toothache*

cavity mempengaruhi probabilitas *catch*

Tetapi ini adalah dua efek yang terpisah!

- Nilai *Toothache* memberi kita info tentang nilai *Catch*, *secara tidak langsung* (lewat *Cavity*).
- Dkl, diberikan nilai *Cavity*, kedua variabel *Toothache* dan *Catch* independent:

$$\mathbf{P}(\textit{toothache} \wedge \textit{catch} | \textit{Cavity}) = \mathbf{P}(\textit{toothache} | \textit{Cavity}) \mathbf{P}(\textit{catch} | \textit{Cavity})$$



Conditional independence - 1

Conditional Independence

Conditional independence dua variabel X dan Y , jika diketahui Z :

$$\mathbf{P}(X, Y|Z) = \mathbf{P}(X|Z)\mathbf{P}(Y|Z)$$



Conditional independence - 2

Perhatikan, *full joint distribution* bisa didekomposisi:

$$\begin{aligned} & \mathbf{P}(\textit{Toothache}, \textit{Catch}, \textit{Cavity}) \\ = & \mathbf{P}(\textit{Toothache}, \textit{Catch} | \textit{Cavity}) \mathbf{P}(\textit{Cavity}) \\ = & \mathbf{P}(\textit{Toothache} | \textit{Cavity}) \mathbf{P}(\textit{Catch} | \textit{Cavity}) \mathbf{P}(\textit{Cavity}) \end{aligned}$$

Pengaruh efisiensi

Scr. umum, *conditional independence* mengubah kompleksitas *joint probability distribution* dari **eksponensial** menjadi **linier** dalam jumlah variable.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Review

- Teori probabilitas: merangkum ketidakpastian sebagai suatu bilangan.
- Inference: menggunakan full joint probability distribution untuk menjawab berbagai masalah dalam domain.
Tidak efisien! Kompleksitas untuk n variable: $O(2^n)$!
- Efisiensi: absolute independence & conditional independence. Mengurangi banyaknya nilai probabilitas yang perlu dihitung saat inference.
- Bayes' Rule: inference dengan conditional probability.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference




Bayesian Network

- Notasi graf yang menyatakan *conditional independence* dalam suatu domain.
- **Node** menyatakan sebuah *random variable*.
- Himpunan **directed edge** menghubungkan dua buah nodes untuk menyatakan hubungan pengaruh langsung (direct influence).
 - Jika A adalah **parent** dari B ($A \rightarrow B$), maka B dipengaruhi langsung oleh A (A has *direct influence* on B).
 - Node **sibling** menyatakan variable yang *conditionally independent* jika diketahui parent-nya.
- Conditional distribution untuk setiap node terhadap parent-nya: $\mathbf{P}(X_i | \text{Parents}(X_i))$
- Tidak ada *cycle* di dalam Bayesian Network (d.k.l. directed acyclic graph atau DAG)



Contoh kedokteran gigi

Topologi sebuah Bayesian Network menyatakan hubungan conditional independence:



- *Weather* **absolute independent** dari semua variable lain.
- *Toothache* dan *Catch* **conditionally independent** jika diketahui *Cavity*.



Contoh lain

Anto sedang di kantor. Tetangganya, John, menelepon mengatakan alarm anti-perampoknya bunyi. Tetangganya, Mary, tidak menelepon. Kadang-kadang alarmnya nyala karena gempa bumi. Apakah ada perampok di rumah Anto?



Contoh lain

Anto sedang di kantor. Tetangganya, John, menelepon mengatakan alarm anti-perampoknya bunyi. Tetangganya, Mary, tidak menelepon. Kadang-kadang alarmnya nyala karena gempa bumi. Apakah ada perampok di rumah Anto?

Variable dalam domain:

Burglar, Earthquake, Alarm, JohnCalls, MaryCalls



Contoh lain

Anto sedang di kantor. Tetangganya, John, menelepon mengatakan alarm anti-perampoknya bunyi. Tetangganya, Mary, tidak menelepon. Kadang-kadang alarmnya nyala karena gempa bumi. Apakah ada perampok di rumah Anto?

Variable dalam domain:

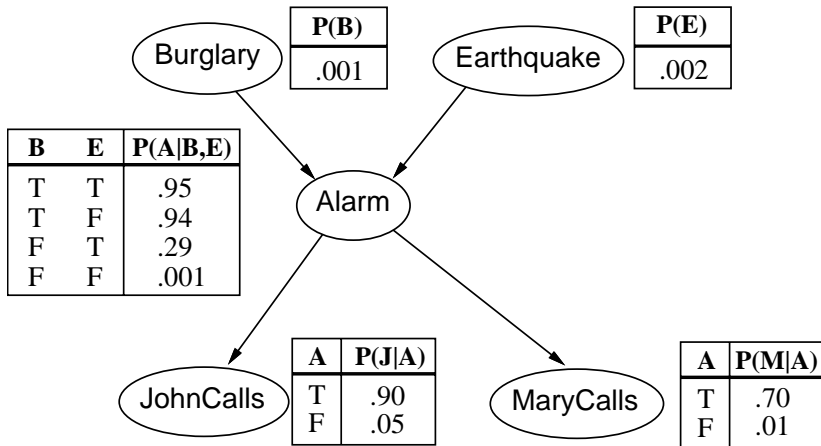
Burglar, Earthquake, Alarm, JohnCalls, MaryCalls

Hubungan sebab akibat:


- Perampok bisa membuat alarm nyala.
- Gempa bumi bisa membuat alarm nyala.
- Alarm bisa membuat John menelepon.
- Alarm bisa membuat Mary menelepon.



Contoh Bayesian Network



Bayesian Network = ringkas



- Conditional probability sebuah node dgn. k parent = $O(2^k)$.
- Untuk n buah variable: $O(n \times 2^k)$
- Bandingkan dengan $O(2^n)$ untuk full joint distribution.



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - **Semantic Bayesian Network**
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Memaknai Bayesian Network

Ada dua cara dalam memahami semantik Bayesian Network, yaitu:

- 1 sebagai representasi dari *full joint probability distribution*
→ membantu dalam membangun Bayesian Network
- 2 sebagai sekumpulan pernyataan *conditional independence*
→ membantu dalam merancang inference procedure



Merepresentasikan full joint distribution

- Bayesian Network adalah deskripsi lengkap sebuah domain.
- Full joint distribution bisa diperoleh dari local conditional distribution:

- $$\mathbf{P}(X_1, \dots, X_n) = \prod_{i=1}^n \mathbf{P}(X_i | \text{Parents}(X_i))$$

- Contoh: hitung probabilitas John menelepon, Mary menelepon, alarm nyala, tidak ada perampok, tidak ada gempa bumi.

$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e) =$$

$$P(j|a)P(m|a)P(a|\neg b, \neg e)P(\neg b)P(\neg e) =$$

$$0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 = 0.00062$$



Chain rule & conditional independence

■ Aturan chain rule:

Product rule dlm conditional probability untuk himpunan random variables:

$$\begin{aligned} P(x_1, \dots, x_n) &= P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1}, \dots, x_1) \\ &= P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1} | x_{n-2}, \dots, x_1) \dots P(x_2 | x_1) P(x_1) \\ &= \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) \end{aligned}$$

■ Pada Bayesian Network, untuk setiap variable X_i berlaku:

$$\mathbf{P}(X_i | X_{i-1}, \dots, X_1) = \mathbf{P}(X_i | \text{Parents}(X_i))$$

dimana $\text{Parents}(X_i) \subseteq \{X_{i-1}, \dots, X_1\}$

■ Mis., berdasarkan chain rule:

$$\mathbf{P}(A, B, C, D) = \mathbf{P}(A | B, C, D) \mathbf{P}(B | C, D) \mathbf{P}(C | D) \mathbf{P}(D)$$

→ Bayesian Network dengan urutan D, C, B, A tanpa conditional independence.

■ Bagaimana jika, mis:

A conditionally independent thd. B karena C dan D

B conditionally independent thd. C karena D :

$$\mathbf{P}(A, B, C, D) = \mathbf{P}(A | C, D) \mathbf{P}(B | D) \mathbf{P}(C | D) \mathbf{P}(D)$$



Membangun Bayesian Network

Membangun Bayesian Network dengan aturan **chain rule**:


Sebuah algoritma:

- 1 Pilih ordering variable X_1, \dots, X_n , idealnya mulai dari *sebab* kemudian *akibat*
- 2 For $i = 1$ to n
 - Tambahkan X_i ke network
 - Pilih (himpunan minimal) parent X_i dari X_1, \dots, X_{i-1} shg.
$$\mathbf{P}(X_i | \text{Parents}(X_i)) = \mathbf{P}(X_i | X_1, \dots, X_{i-1})$$




Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




$$P(J|M) = P(J)?$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




$$P(J|M) = P(J)? \text{ Tidak}$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)?$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.




$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \text{ Tidak}$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \text{ Tidak}$$


$$P(B|A, J, M) = P(B|A)?$$

$$P(B|A, J, M) = P(B)?$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \text{ Tidak}$$


$$P(B|A, J, M) = P(B|A)? \text{ Ya}$$

$$P(B|A, J, M) = P(B)? \text{ Tidak}$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$P(J|M) = P(J)$? **Tidak**

$P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$? **Tidak**

$P(B|A, J, M) = P(B|A)$? **Ya**


$P(B|A, J, M) = P(B)$? **Tidak**

$P(E|B, A, J, M) = P(E|A)$?



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$P(J|M) = P(J)$? **Tidak**

$P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$? **Tidak**

$P(B|A, J, M) = P(B|A)$? **Ya**


$P(B|A, J, M) = P(B)$? **Tidak**

$P(E|B, A, J, M) = P(E|A)$? **Tidak**



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \text{ Tidak}$$

$$P(B|A, J, M) = P(B|A)? \text{ Ya}$$

$$P(B|A, J, M) = P(B)? \text{ Tidak}$$


$$P(E|B, A, J, M) = P(E|A)? \text{ Tidak}$$

$$P(E|B, A, J, M) = P(E|A, B)?$$



Contoh membangun Bayesian Network

Mis. kita pilih urutan: *MaryCalls*, *JohnCalls*, *Alarm*, *Burglary*, *Earthquake*.



$$P(J|M) = P(J)? \text{ Tidak}$$

$$P(A|J, M) = P(A|J)? \quad P(A|J, M) = P(A)? \text{ Tidak}$$

$$P(B|A, J, M) = P(B|A)? \text{ Ya}$$


$$P(B|A, J, M) = P(B)? \text{ Tidak}$$

$$P(E|B, A, J, M) = P(E|A)? \text{ Tidak}$$

$$P(E|B, A, J, M) = P(E|A, B)? \text{ Ya}$$



Mulailah dari penyebab



- Menentukan **conditional independence** sulit untuk arah non-causal.
 - Akibatnya, ada penambahan *dependency* antara penyebab yang saling independent
- Menghitung **conditional probability** sulit untuk arah non-causal.
 - Lebih mudah menghitung nilai probability dari aturan kausal ketimbang diagnostik!
- *Conditional independence* lebih **intuitif** pada *causal model*!
- Kesimpulan: mulai dari variable “sebab” dulu.



Naive vs. paranoid...

Naive Bayes model

Semua variable **akibat** dianggap saling *conditionally independent* karena variable **sebab**.

$$\mathbf{P}(\text{Sebab}, \text{Akibat}_1, \dots, \text{Akibat}_n) = \mathbf{P}(\text{Sebab}) \prod_i \mathbf{P}(\text{Akibat}_i | \text{Sebab})$$

Full joint distribution (paranoid?)

Semua random variable dianggap saling mempengaruhi.

Yang kita cari: analisis **domain-specific** yang menghasilkan informasi **conditional independence** yang benar!



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - **Efficient representation of conditional distributions**
 - Exact vs Approximate Inference



Deterministic nodes

- *Conditional distribution* sebuah node dgn. k parent exponential dlm. k .
- Ada beberapa representasi yang lebih efisien → **canonical distribution**
- Conditional distribution dari suatu **deterministic node** bisa dihitung sepenuhnya dari nilai *parent*-nya. Contoh
 - Relasi logik: Sekumpulan *parent nodes*: *Canadian*, *US*, *Mexican* dan sebuah *child node*: *NorthAmerican*, maka *child node* adalah disjungsi semua *parent nodes*.
 - Relasi numerik: Sekumpulan *parent nodes*: harga suatu mobil jenis tertentu pada beberapa dealer dan sebuah *child node*: batas harga yang dapat ditawarkan pembeli, maka *child node* adalah minimum value dari *parent nodes*.



Deterministic nodes

- Representasi dari conditional distribution dapat dinyatakan dalam relasi **Noisy-OR**, yaitu generalisasi dari logical-OR.
- Sebagai contoh, dalam propositional logic, kita dapat nyatakan: $Fever \Leftrightarrow Cold \vee Flu \vee Malaria$
- Noisy-OR mengijinkan *ketidakpastian* pengaruh parent untuk menentukan nilai kebenaran child node. Contoh: Pasien mengalami *Cold*, tapi tidak berakibat ia mengalami *Fever*.
- Dalam model yang menggunakan Noisy-OR, terdapat dua asumsi:
 - semua kemungkinan penyebab diketahui (jika tidak, cukup tambahkan sebuah node berlabel "Lain-lain" disebut sebagai **leak node**)
 - pengaruh suatu parent terhadap child node bersifat independent terhadap parent lain dari child tersebut.



Noisy-OR Distribution

Contoh:

$$P(\neg \text{fever} | \text{cold}, \neg \text{flu}, \neg \text{malaria}) = 0.6$$

$$P(\neg \text{fever} | \neg \text{cold}, \text{flu}, \neg \text{malaria}) = 0.2$$

$$P(\neg \text{fever} | \neg \text{cold}, \neg \text{flu}, \text{malaria}) = 0.1$$

$$P(x_i | \text{parents}(X_i)) = 1 - \prod_{j: X_j = \text{true}} q_j$$

<i>Cold</i>	<i>Flu</i>	<i>Malaria</i>	$P(\text{Fever})$	$P(\neg \text{Fever})$
F	F	F	0.0	1.0
F	F	T	0.9	0.1
F	T	F	0.8	0.2
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	0.6
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

Jumlah parameter **linier** thd. jumlah *parent*



Outline

- 1 Bertindak dalam Ketidakpastian (*Uncertainty*)
- 2 Mengukur Ketidakpastian
 - Notasi Dasar Probabilitas
 - Inference
 - Kompleksitas
- 3 *Efficient* probabilistic reasoning
 - (Absolute) Independence
 - Bayes' Rule & Conditional Independence
- 4 Bayesian Networks
 - Knowledge Representation dalam Ketidakpastian
 - Semantic Bayesian Network
 - Efficient representation of conditional distributions
 - Exact vs Approximate Inference



Inference by enumeration (1)


- Suatu *conditional probability* dapat dihitung dengan menjumlahkan semua variable dari *full joint distribution*.
- X menyatakan *query variable*; \mathbf{E} menyatakan himpunan *evidence variable*, \mathbf{e} merupakan event yang diobservasi; \mathbf{Y} adalah *hidden variables*
 $\mathbf{P}(X|\mathbf{e}) = \alpha \mathbf{P}(X, \mathbf{e}) = \alpha \sum_{\mathbf{y}} \mathbf{P}(X, \mathbf{e}, \mathbf{y})$
- Contoh: hitung probabilitas ada perampok jika John dan Mary menelepon.

$$\begin{aligned}
 P(b|j, m) &= \alpha \sum_e \sum_a P(b)P(e)P(a|b, e)P(j|a)P(m|a) \\
 &= \alpha P(b) \sum_e P(e) \sum_a P(a|b, e)P(j|a)P(m|a)
 \end{aligned}$$



Inference by enumeration (2)

$$P(b|j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a|b, e) P(j|a) P(m|a)$$



Perhatikan bahwa $P(j|a)P(m|a)$ dihitung untuk setiap nilai e . Gunakan **dynamic programming**: hitung sekali, simpan hasilnya!



Approximate inference

Pendekatan lain: jangan hitung nilai persis, tapi cukup di-sample (Monte Carlo).

Direct sampling methods

function PRIOR-SAMPLE(bn) **returns** an event sampled from bn
inputs: bn , a Bayesian network specifying joint distribution $P(X_1, \dots, X_n)$

$x \leftarrow$ an event with n elements

foreach variable X_i **in** X_1, \dots, X_n **do**

$x[i] \leftarrow$ a random sample from $P(X_i \mid \text{Parents}(X_i))$

return x

function REJECTION-SAMPLING(X, e, bn, N) **returns** an estimate of $P(X|e)$

local variables: N , a vector of counts over X , initially zero

for $j = 1$ **to** N **do**

$x \leftarrow$ PRIOR-SAMPLE(bn)

if x is consistent with e **then**

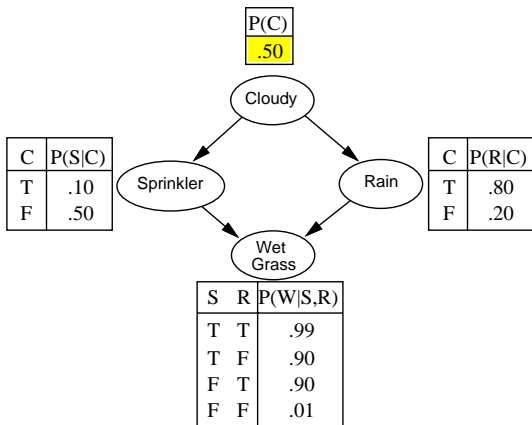
$N[x] \leftarrow N[x] + 1$ where x is the value of X in x

return NORMALIZE(N)



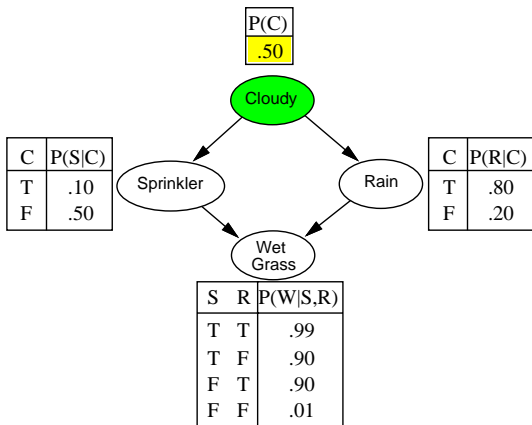
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



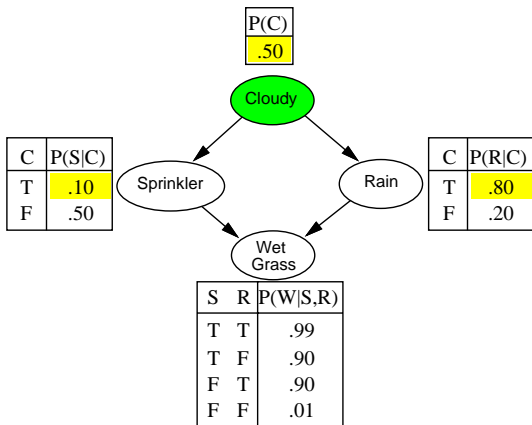
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



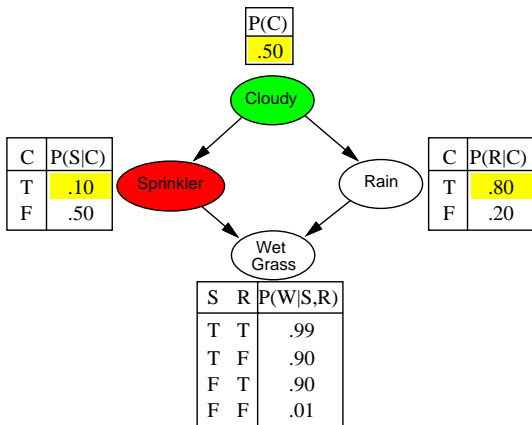
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



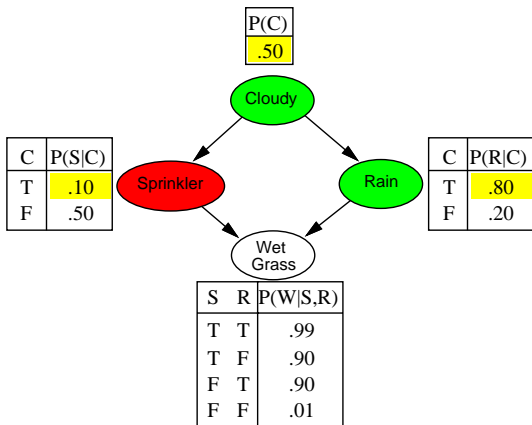
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



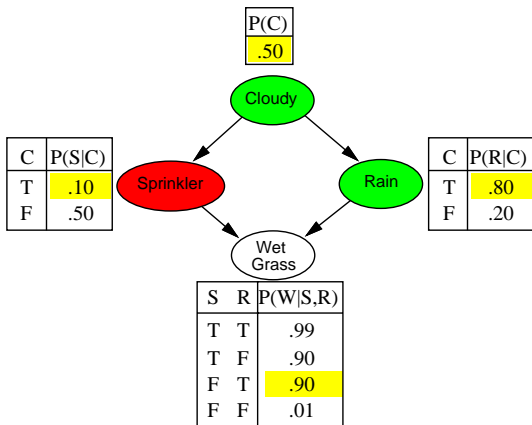
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



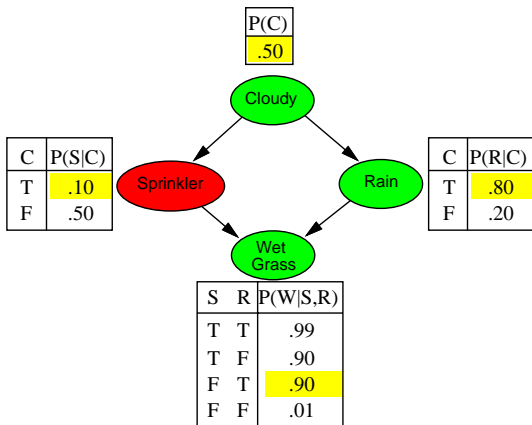
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy, Sprinkler, Rain, WetGrass*]



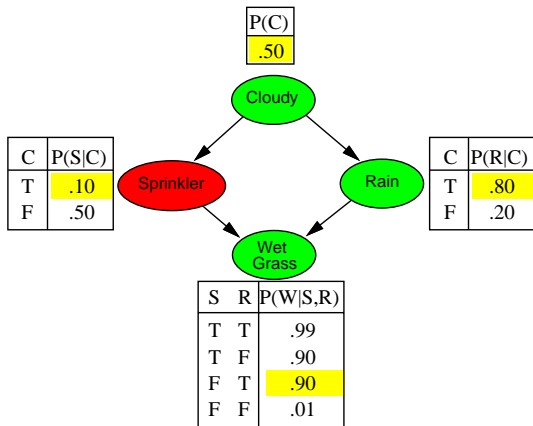
Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



Contoh sampling dengan PRIOR-SAMPLE

Asumsi urutan variable yang diproses: [*Cloudy*, *Sprinkler*, *Rain*, *WetGrass*]



PRIOR-SAMPLE menghasilkan event: [*true*, *false*, *true*, *true*].



Contoh sampling dengan REJECTION-SAMPLING

- Diasumsikan kita ingin mengestimasi distribusi $\mathbf{P}(\text{Rain}|\text{Sprinkler} = \text{true})$ dalam 100 sample.
- Dari 100 kali sample, ternyata 73 kali menghasilkan $\text{Sprinkler} = \text{false}$, dan 27-nya $\text{Sprinkler} = \text{true}$.
- Hasil sample $\text{Sprinkler} = \text{false} \Rightarrow$ tidak konsisten. Rejected!
- Dari 27 sample yang menghasilkan $\text{Sprinkler} = \text{true}$ didapat 8 $\text{Rain} = \text{true}$ dan 19 $\text{Rain} = \text{false}$.
- $\mathbf{P}(\text{Rain}|\text{Sprinkler} = \text{true}) \approx \text{Normalize}(\langle 8, 19 \rangle) = \langle 0.296, 0.704 \rangle$



Ringkasan (1): Probability sebagai KRL

- Teori probabilitas adalah bahasa formal yang dapat merepresentasikan pengetahuan tidak pasti (uncertain knowledge).
- Nilai probabilitas menyatakan keadaan knowledge/belief sebuah agent.
- Sebuah **joint probability distribution** mendefinisikan **prior probability** untuk setiap **atomic event**.
- Inference dicapai dengan menjumlahkan nilai probabilitas.



Ringkasan (2): Probabilistic inference secara efisien

- Inference dengan *full joint distribution* konsepnya sangat mudah dimengerti, tetapi dalam kenyataan tidak feasible (*exponential time & space complexity*)
- Agar inference bisa *tractable*, kita mengambil asumsi **independence**.
- Dalam kenyataan, kita hanya bisa mengambil asumsi **conditional independence**.
- **Bayes' Rule**, ditambah dengan *conditional independence*, adalah mekanisme yang *sangat* berguna.



Ringkasan (3): Bayesian networks

- **Bayes Net** cocok utk. representasi (causal) conditional independence
- Mulai dari variable *penyebab*, tambahkan variable *akibat*
- **Compact conditional distribution** dengan representasi canonical
- **Exact** inference bisa dipercepat dengan **dynamic programming**
- **Approximate** inference bisa dilakukan dengan **sampling**

